

Санкт-Петербургский национальный исследовательский университет
информационных технологий, механики и оптики
Факультет информационных технологий и программирования
Кафедра компьютерных технологий

**Реализация эффективного взаимодействия между
платформой для анализа экспрессии генов Morpheus и
библиотекой вычислительных методов R/Bioconductor**

Зенкова Д.М.

Научный руководитель: Сергушичев А. А.

Санкт-Петербург
2017

ОГЛАВЛЕНИЕ

Стр.

ВВЕДЕНИЕ	6
ГЛАВА 1. ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ	7
1.1. Биоинформатика	7
1.1.1. Анализ экспрессии генов.....	7
1.1.2. Используемые методы	7
1.2. Существующие решения для анализа экспрессии генов ...	7
1.2.1. GENE-E	7
1.2.2. morpheus.js	7
1.2.3. R/Bioconductor.....	8
1.3. Инструменты, которые могут быть применены	8
1.3.1. Язык R и библиотека Bioconductor.....	8
1.3.2. JavaScript	8
1.3.3. R shiny	8
1.3.4. OpenCPU	8
1.3.5. Gene Expression Omnibus.....	8
1.3.6. Docker	9
1.3.7. JSON.....	9
1.3.8. Protocol Buffers	9
1.3.9. Apache2.....	9
1.3.10. HTML.....	9
1.4. Постановка задачи	9
1.4.1. Цель работы	9
1.4.2. Основные задачи	9
1.4.3. Требования к веб-приложению phantasus	10
Выводы по главе 1.....	10
ГЛАВА 2. АРХИТЕКТУРА ПРОЕКТА	11
2.1. Рассортировать по секциям	11
2.1.1. Реализация Dataset в morpheus.js	11
2.1.2. Стандартный класс ExpressionSet	11
2.1.3. opencpu.js	11
2.1.4. Protocol Buffers	11
2.1.5. Схема взаимодействия клиент-сервер	11
2.1.6. Загрузка и разбор данных из GEO	11
2.1.7. Загрузка данных в phantasus	11
2.1.8. Аннотации строк и столбцов матрицы	12

2.1.9. Git-репозиторий phantasmus	12
2.1.10. Запуск phantasmus локально и на сервере	12
2.1.11.	12
Выводы к главе 2	12
ГЛАВА 3. РЕАЛИЗАЦИЯ	13
Выводы к главе 3	13
ЗАКЛЮЧЕНИЕ	14
СПИСОК ИСТОЧНИКОВ	15

ВВЕДЕНИЕ

ГЛАВА 1. ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ

1.1. Биоинформатика

1.1.1. Анализ экспрессии генов

1.1.2. Используемые методы

1.2. Существующие решения для анализа экспрессии генов

1.2.1. GENE-E

GENE-E - Платформа для анализа данных и визуального исследования данных, созданная на Java и R [1]. Содержит в себе множество полезных для исследования инструментов: тепловые карты, кластеризацию, фильтрацию, построение графиков и т.д. Позволяет исследовать любые данные в виде матрицы. К тому же, содержит дополнительные инструменты для геномных данных.

Недостатки:

- Чтобы использовать, необходимо устанавливать на свой компьютер;
- Поддержка данного приложения прекратилась в связи с созданием morpheus.js;
- Не имеет открытого исходного кода, а только API.

1.2.2. morpheus.js

Morpheus.js - веб-приложение для визуализации и анализа матриц от создателя GENE-E [2]. Создано уже на JavaScript и с открытым исходным кодом. Удобно для использования исследователями без навыков программирования и так же, как и GENE-E, применимо к любым матрицам.

Недостатки:

- Ограниченный набор функций, которых недостаточно для полноценного анализа;
- Для расширения биоинформатическими алгоритмами требуется реализовывать их заново на JavaScript.

1.2.3. R/Bioconductor

R - язык программирования для статистического анализа данных и работы с графикой. Bioconductor - библиотека, содержащая в себе множество реализаций биоинформатических алгоритмов и методов обработки биологических данных на R. Она постоянно обновляется, пополняется новыми библиотеками, модерируется сообществом. R и Bioconductor очень популярны в биоинформатической среде ввиду предоставляемых возможностей.

Однако для качественного и полноценного анализа с помощью этих инструментов, нужно иметь навыки программирования на R, что весьма неудобно для исследователей биологических специальностей.

1.3. Инструменты, которые могут быть применены

1.3.1. Язык R и библиотека Bioconductor

Алгоритмы, реализованные в Bioconductor, могут быть применены для анализа экспрессии генов.

1.3.2. JavaScript

JavaScript - язык программирования, широко используемый для написания веб-приложений.

1.3.3. R shiny

1.3.4. OpenCPU

OpenCPU - система для встроенных научных вычислений и воспроизводимых исследований, предоставляющая HTTP API для взаимодействия с R-серверами. Имеется также библиотека opencpu.js для интеграции JavaScript и R.

1.3.5. Gene Expression Omnibus

GEO - публичный репозиторий с геномными данными.

В библиотеке Bioconductor есть R-пакет GEOquery для удобной загрузки данных из GEO.

1.3.6. Docker

1.3.7. JSON

1.3.8. Protocol Buffers

1.3.9. Apache2

1.3.10. HTML

1.4. Постановка задачи

Рассмотрев существующие решения для анализа экспрессии генов и инструментов, которые могли бы пригодиться для будущих решений, можно сформулировать цель и основные задачи данной работы

1.4.1. Цель работы

Создать веб-приложение, интегрирующее существующие возможности веб-приложения morphheus.js и методы анализа, реализованные в Bioconductor.

1.4.2. Основные задачи

- а) Разработать способ взаимодействия между js-клиентом и R и встроить его в morphheus.js, чтобы избежать реализации с нуля уже существующих алгоритмов;
- б) Реализовать графический интерфейс в js-клиенте и серверную реализацию в R-пакете;
- в) Соединить все составляющие в одном веб-приложении phantassus;
- г) Запустить веб-приложение в открытый доступ для исследователей.

1.4.3. Требования к веб-приложению phantasus

Доступность

Необходимо, чтобы веб-приложение phantasus было доступно для исследователей независимо от их местоположения и времени суток. Варианты действий:

- а) Сделать его доступным по определенному веб-адресу, и тогда пользователь сможет продолжать исследования из любой точки, где есть подключение к интернету;
- б) Предоставить возможность запускать приложение локально, например, с помощью Docker или внутри R.

Возможность дальнейшего расширения функционала веб-приложения

Как уже было сказано выше, библиотека Bioconductor постоянно обновляется и пополняется новыми алгоритмами, а исследователи находят новые методы для анализа экспрессии генов, так что необходимо не только реализовать дополнительные методы, но и отладить и описать алгоритм действий для добавления новых.

Выводы по главе 1

В данной главе была кратко описана предметная область и необходимые биоинформатические определения, рассмотрены существующие решения и инструменты, которые могли бы быть применены для разработки новых решений. Исходя из обзора, была сформулирована цель работы и требования к результату:

- а) доступность;
- б) возможность дальнейшего расширения функционала.

ГЛАВА 2. АРХИТЕКТУРА ПРОЕКТА

В этой главе будут подробно рассмотрены элементы проекта, их взаимосвязь и ключевые для архитектуры выдержки из исходного кода.

2.1. Рассортировать по секциям

2.1.1. Реализация Dataset в morpheus.js

В исходном коде morpheus.js имеется класс для работы с данными, позволяющий рассматривать сечения, работать с аннотациями, в целом, осуществлять любое взаимодействие с имеющимися данными. Код представлен на листинге 2.1.

Листинг 2.1 — класс Dataset

2.1.2. Стандартный класс ExpressionSet

2.1.3. opencpu.js

2.1.4. Protocol Buffers

На стороне клиента

На стороне сервера

2.1.5. Схема взаимодействия клиент-сервер

2.1.6. Загрузка и разбор данных из GEO

2.1.7. Загрузка данных в phantasus

Из файла

- а) My computer;
- б) URL;
- в) Dropbox.

Из GEO

2.1.8. Аннотации строк и столбцов матрицы

2.1.9. Git-репозиторий phantasus

2.1.10. Запуск phantasus локально и на сервере

2.1.11.

Выводы к главе 2

ГЛАВА 3. РЕАЛИЗАЦИЯ

Выводы к главе 3

ЗАКЛЮЧЕНИЕ

СПИСОК ИСТОЧНИКОВ

1. Gould Joshua. GENE-E. [Электронный ресурс]. URL: <http://www.broadinstitute.org/cancer/software/GENE-E/>.
2. Gould Joshua. morpheus.js. [Электронный ресурс]. URL: <https://clue.io/morpheus.js/>.